

Homework 8

陈远洋

Problem 1

Assume C is a convex set, show that $x^* \in \operatorname{argmin}_{y \in C} \frac{1}{2} \|x - y\|_2^2$ if and only if for any $y \in C$, $\langle x - x^*, y - x^* \rangle \leq 0$.

证明. 先证明充分性: $x^* \in \operatorname{argmin}_{y \in C} \frac{1}{2} \|x - y\|_2^2 \Rightarrow \forall y \in C, \langle x - x^*, y - x^* \rangle \leq 0$

若 $x^* \in \operatorname{argmin}_{y \in C} \frac{1}{2} \|x - y\|_2^2$, 则 $\forall y \in C$, 有:

$$\begin{aligned} \frac{1}{2} (\|x - y\|_2^2 - \|x - x^*\|_2^2) &= \frac{1}{2} (\|x - x^* + x^* - y\|_2^2 - \|x - x^*\|_2^2) \\ &= \frac{1}{2} (\langle x^* - y, x^* - y \rangle - 2\langle x - x^*, y - x^* \rangle) \\ &\geq 0 \end{aligned}$$

而若 $\exists y_0 \in C$ s.t. $\langle x - x^*, y_0 - x^* \rangle > 0$, 取 $\alpha \in (0, 1)$. 由 C 是凸集且 $x^*, y_0 \in C$ 故 $\forall \alpha \in (0, 1)$: $x^* + \alpha(y_0 - x^*) \in C$ 令 $g(\alpha) = \frac{1}{2} \|x - x^* + \alpha(y_0 - x^*)\|_2^2 - \frac{1}{2} \|x - x^*\|_2^2$, 而进一步展开:

$$\begin{aligned} g(\alpha) &= \frac{\alpha^2}{2} \langle x^* - y_0, x^* - y_0 \rangle - \alpha \langle x - x^*, y_0 - x^* \rangle \\ &= \frac{\alpha}{2} (\alpha \|x^* - y_0\|_2^2 - 2\langle x - x^*, y_0 - x^* \rangle) \end{aligned}$$

则 $\forall \alpha \in (0, 1) \cap (0, \frac{\langle x - x^*, y_0 - x^* \rangle}{\|x^* - y_0\|_2^2})$: $g(\alpha) < \frac{\alpha}{2} (\frac{\langle x - x^*, y_0 - x^* \rangle}{\|x^* - y_0\|_2^2} \|x^* - y_0\|_2^2 - 2\langle x - x^*, y_0 - x^* \rangle) = -\frac{\alpha}{2} \langle x - x^*, y_0 - x^* \rangle < 0$ 这与 x^* 是最优解的条件矛盾, 故不存在这样的 y_0 . 也即 $\forall y \in C, \langle x - x^*, y - x^* \rangle \leq 0$

再来看必要性: $\forall y \in C, \langle x - x^*, y - x^* \rangle \leq 0 \Rightarrow x^* \in \operatorname{argmin}_{y \in C} \frac{1}{2} \|x - y\|_2^2$

若 $\forall y \in C : \langle x - x^*, y - x^* \rangle \leq 0$ 且 $\exists \bar{x} \neq x^* \in C : \|\bar{x} - x^*\|_2^2 < \|x - x^*\|_2^2$ (即 x^* 并非最优点) 那么有:

$$\begin{aligned} \|x - \bar{x}\|_2^2 - \|x - x^*\|_2^2 &= \langle x - x^* + x^* - \bar{x}, x - x^* + x^* - \bar{x} \rangle - \langle x - x^*, x - x^* \rangle \\ &= 2\langle x - x^*, x^* - \bar{x} \rangle + \|\bar{x} - x^*\|_2^2 \\ &< 0 \end{aligned}$$

可得 $\langle x - x^*, \bar{x} - x^* \rangle > \frac{1}{2} \|\bar{x} - x^*\|_2^2 > 0$ 矛盾! 故不存在这样的 \bar{x} 也即 $x^* \in \operatorname{argmin}_{y \in C} \frac{1}{2} \|x - y\|_2^2$. \square

Problem 2

Use the optimality conditions to solve the following problem:

$$\begin{aligned} \min_{x \in \mathbb{R}^n} f(x) \\ \text{s.t. } h(x) = 0, \end{aligned}$$

where

(a) $f(x) = \|x\|_2^2, h(x) = \sum_{i=1}^n x_i - 1.$

(b) $f(x) = \sum_{i=1}^n x_i, h(x) = \|x\|_2^2 - 1.$

(c) $f(x) = \|x\|_2^2, h(x) = x^T Q x - 1$, where Q is positive definite.

- (a) 由一阶必要条件 $\exists \lambda$, 对 $L(x; \lambda) = f(x) - \lambda h(x)$ 有:
$$\begin{cases} h(x) = \sum_{i=1}^n x_i - 1 = 0 \\ \nabla f(x) - \lambda \nabla h(x) = 2x - \lambda \vec{1} = 0 \end{cases}$$

联合两式解得 $x_i = \frac{1}{n}, i = 1, 2, \dots, n$. 而 $\nabla_{xx}^2 L(x) = 2I, \nabla h(x) = \vec{1}$, 代入二阶充分条件 $d^T \nabla_{xx}^2 L(x) d > 0, \forall d \neq 0: d^T \nabla h(\frac{\vec{1}}{n}) = 0$ 成立, 所以 $\frac{\vec{1}}{n}$ 是最优解. 对应函数值为 $f(x) = \frac{1}{n}$

- (b) 由一阶必要条件 $\exists \lambda$, 对 $L(x; \lambda) = f(x) - \lambda h(x)$ 有:
$$\begin{cases} h(x) = \langle x, x \rangle - 1 = 0 \\ \nabla f(x) - \lambda \nabla h(x) = \vec{1} - 2\lambda x = 0 \end{cases}$$

联合两式解得 $x_i^2 = \frac{1}{n}, i = 1, 2, \dots, n$, 且 $x_1 = \dots = x_n$. 而 $\nabla_{xx}^2 L(x) = -2\lambda I, \nabla h(x) = 2x$, 代入二阶充分条件 $d^T \nabla_{xx}^2 L(x) d > 0, \forall d \neq 0: d^T \nabla h(x) = 0$. 解得 $\lambda < 0$, 则可得 $x_i = \frac{-1}{\sqrt{n}}$ 为最优解. 对应函数值为 $f(\frac{-1}{\sqrt{n}}) = -\sqrt{n}$

- (c) 由一阶必要条件 $\exists \lambda$, 对 $L(x; \lambda) = f(x) - \lambda h(x)$ 有:
$$\begin{cases} h(x) = x^T Q x - 1 = 0 \\ \nabla f(x) - \lambda \nabla h(x) = 2x - 2\lambda Q x = 0 \end{cases}$$

如果 $\lambda = 0$ 那么由第二个等式可推出 $x = 0$ 与第一式矛盾, 所以 $\lambda \neq 0$ 所以原来的

等式可以改写为:
$$\begin{cases} x^T Q x = 1 \\ (Q - \frac{1}{\lambda} I) x = 0 \end{cases}$$
 可以看出, 这是一个特征值问题. 代入 $f(x)$ 可得

$f(x) = x^T x = x^T \lambda Q x = \lambda$. 而容易看出 $\frac{1}{\lambda}$ 为 Q 的特征值. 要想求出 $f(x)$ 的最小值, 我们需要 $\frac{1}{\lambda}$ 尽可能大. 于是取 $\frac{1}{\lambda} = \|Q\|_2 = \rho(Q), x^*$ 为对应的模长为 $\|Q\|_2^{-\frac{1}{2}}$ 特征向量. 而 $\nabla_{xx}^2 L(x) = 2(I - \lambda Q), \nabla h(x) = 2Qx$. 而由于 $d \perp \operatorname{span}\{x^*\}$, $d^T Q d < d^T d \|Q\|_2$, 代入二阶充分条件 $d^T \nabla_{xx}^2 L(x^*) d > 0, \forall d \neq 0: d^T \nabla h(x^*)$ 成立. 进一步推出该点为最优点. 对应函数值为 $f(x^*) = \frac{1}{\|Q\|_2}$

Problem 3

Consider a symmetric $n \times n$ matrix Q . Define

$$\lambda_1 = \min_{\|x\|_2^2=1} x^T Q x, \quad e_1 \in \operatorname{argmin}_{\|x\|_2^2=1} x^T Q x,$$

and for $k = 0, \dots, n-1$,

$$\lambda_{k+1} = \min_{\substack{\|x\|_2^2=1 \\ e_i^T x = 0, i=1, \dots, k}} x^T Q x, \quad e_{k+1} \in \operatorname{argmin}_{\substack{\|x\|_2^2=1 \\ e_i^T x = 0, i=1, \dots, k}} x^T Q x$$

(a) Show that

$$\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n.$$

(b) Show that the vectors e_1, \dots, e_n are linearly independent.

(c) Interpret $\lambda_1, \lambda_2, \dots, \lambda_n$ as Lagrange multipliers, and show that $\lambda_1, \lambda_2, \dots, \lambda_n$ are the eigenvalues of Q , while e_1, \dots, e_n are corresponding eigenvectors.

证明. (a) 从直观上来看, 由于越往后约束更多. 所以最优点函数值一定越来越大. 作以下严格证明:

如果 $\exists k, \text{s.t. } \lambda_k > \lambda_{k+1}$ 那么 $e_{k+1}^T Q e_{k+1} = \lambda_{k+1} < \lambda_k$ 且:
$$\begin{cases} \|e_{k+1}\|_2 = 1 \\ e_j^T e_{k+1} = 0 \quad \forall j < k (k > 1) \end{cases} \quad \text{即 } e_{k+1}$$

是可行的. 那么这与 λ_k 是子问题的最优解函数值矛盾! 所以 $\forall k, \lambda_k \leq \lambda_{k+1}$ 即 $\lambda_1 \leq \lambda_2 \leq \dots \leq \lambda_n$.

(b) 由第 k 步条件 ($k > 1$): $e_i^T x = 0, \forall i < k$ 并且 e_k 是可行的所以 $e_i^T e_k = 0, \forall i < k$. 如果 e_1, \dots, e_n 不是线性无关. 那么就 $\exists k, \text{s.t. } e_k$ 可以由前 $k-1$ 个向量线性表出 (i.e. k 可以取线性组合为 0 的最大不为 0 系数对应下标). 而这与正交性条件矛盾: $0 < e_k^T e_k = e_k^T (\sum_{i=1}^{k-1} \alpha_i e_i) = 0$. 所以 e_1, \dots, e_n 线性无关.

(c) 令 $f(x) = x^T Q x, h(x) = \|x\|_2^2 - 1 = \langle x, x \rangle - 1$ 定义问题 1:

$$\begin{aligned} & \min_{x \in \mathbb{R}^n} f(x) \\ & \text{s.t. } h(x) = 0 \end{aligned}$$

应用拉格朗日乘子 λ , 得到拉格朗日函数 $L(x; \lambda) = f(x) - \lambda h(x)$. 由一阶必要条件 $\nabla f(x) - \lambda \nabla h(x) = 2(Q - \lambda I)x = 0$ 化简得到 $(Q - \lambda I)x = 0$ 左乘 x 得到 $f(x) = \lambda$ 而这个等式是一个特征值问题, 蕴含 λ, x 分别是 Q 的特征值与特征向量. 此时 $\nabla_{xx}^2 L = 2(Q - \lambda I)$, 代入二阶充分条件 $d^T \nabla_{xx}^2 L d > 0, \forall d \neq 0: d^T \nabla h(x) = 0$. 显然此时 λ 取 Q 最小的特征值可以使得函数值最优. 对应本问题我们得到 λ_1 与 e_1 是 Q 的特征值与特征向量.

假设我们要证明的命题： λ_i, e_i 是 Q 的第 i 个特征对在前 k 对成立，采用数学归纳法，下证 $k+1$ 时的情况：在问题 k 的基础上定义问题 $k+1$

$$\begin{aligned} & \min_{x \perp \text{span}\{e_1, \dots, e_k\}} f(x) \\ & \text{s.t. } h(x) = 0 \end{aligned}$$

引入乘子 $\mu_1, \dots, \mu_k, \lambda$ ，得到拉格朗日函数 $L(x; \lambda; \mu) = f(x) - \lambda h(x) - \sum_{i=1}^k \mu_i x^T e_i$ 。由一阶必要条件 $\nabla f(x) - \lambda \nabla h(x) - \sum_{i=1}^k \mu_i e_i = 0$ 化简得到 $(Q - \lambda I)x = \sum_{i=1}^k \frac{\mu_i}{2} e_i$ 分别左乘 $e_i, i = 1, \dots, k$ 得到 $e_i^T Q x = \lambda_i e_i^T x = 0 = \frac{\mu_i}{2}$ 。再左乘 x 得到 $x^T Q x = \lambda x^T x = \lambda$ 由上面两个条件，必要条件进一步化简为： $(Q - \lambda I)x = 0$ 而这同样是一个特征值问题，蕴含 λ, x 分别是 Q 的特征值与特征向量。由于已经求出 $\mu_i = 0$ ，此时 $\nabla_{xx}^2 L = 2(Q - \lambda I)$ ，同样代入二阶充分条件 $d^T \nabla_{xx}^2 L d > 0, \forall d \neq 0 : d^T \nabla h(x) = 0$ ，注意此时方向 d 的选取局限在前 k 个特征向量的补空间。显然此时 λ 取 Q 第 $k+1$ 最小的特征值可以使得函数值最优。（由于前面已经取过前 k 小特征对了）故对应 λ_{k+1} 与 e_{k+1} 是 Q 的第 $k+1$ 小的特征值与特征向量。

综上所述，将 λ_i 作为 Lagrange 乘子的情况下，我们得到了 $\lambda_1, \lambda_2, \dots, \lambda_n$ 是 Q 的特征值，而 e_1, \dots, e_n 是对应特征向量。 \square